

Deep Reinforcement Learning for Beer Game Supply Chain Ordering

2026 年 6 月 30 日

摘要

啤酒游戏 (Beer Game) 是供应链管理与多智能体强化学习中的经典实验平台。本研究基于课程提供的三阶串行供应链环境，针对单企业利润优化任务，系统复现并改进了 DQN、PPO 与 SAC 三类深度强化学习算法。研究重点在于：在保持环境机制 ($t+1$ 到货延迟、局部 3 维观测) 不变的前提下，通过算法稳定化技巧 (GAE、reward scaling、KL early stopping、best-checkpoint 恢复) 以及 reward shaping / centralized critic 等算法扩展，提升 PPO 在该离散订货任务上的稳定性与最终性能。实验结果表明，Dueling Double DQN 仍是当前最稳健的基线 (3-seed 平均奖励 804.46)，而改进后的 PPO 在多数 seed 上达到 790–830 区间，但尚未在所有 seed 上稳定超过 DQN。本报告记录了研究方案、核心实现、实验结果与未来方向。

1 引言

啤酒游戏模拟了由零售商、批发商、制造商等组成的多阶串行供应链。每阶企业仅掌握局部信息 (自身库存、到货、需求)，需要在需求波动、订货延迟和库存成本之间做出订货决策。由于牛鞭效应 (bullwhip effect)，局部理性决策往往导致系统整体低效，是研究多智能体协作与分散决策的典型场景。

本课题的任务目标为：选择链上一个企业，通过深度强化学习优化其长期累积利润，其余企业视为环境的一部分。本研究围绕以下问题展开：

- (1) 在课程基线 DQN 上，Double DQN、Dueling 网络等改进能否带来稳定提升？
- (2) 策略梯度类方法 (PPO) 在该离散、短 episode、随机背景策略的任务上表现如何？
- (3) 通过 reward shaping、centralized critic、best checkpoint 等算法扩展，能否让 PPO 稳定超过基于值函数的方法？

2 环境设定

2.1 供应链结构

实验环境包含 3 个串行企业：

$$\text{外部顾客} \rightarrow \text{企业 0} \rightarrow \text{企业 1} \rightarrow \text{企业 2}. \quad (1)$$

本研究固定优化企业 1 (中间商)，其余企业由背景策略控制。每个企业的局部观测为 3 维向量：

$$s_t = [\text{上一期订货量}, \text{上一期满足需求量}, \text{当前库存}]. \quad (2)$$

动作空间为离散集合 $a_t \in \{0, 1, \dots, 20\}$, 表示当前向上游的订货量。

2.2 $t + 1$ 到货机制

环境采用课程原始设定: t 时刻发出的订单不会立即进入库存, 而是在 $t + 1$ 时刻作为在途货物到达。该延迟加剧了需求信息扭曲, 是牛鞭效应的主要来源之一。

2.3 奖励函数

单步奖励按当期利润计算:

$$r_t = p_i \cdot d_i^{\text{sat}} - p_{i+1} \cdot o_i - h \cdot I_i - c \cdot \max(D_i - d_i^{\text{sat}}, 0), \quad (3)$$

其中 p_i 为售价, p_{i+1} 为采购价, h 为单位库存持有成本, c 为单位缺货惩罚, I_i 为库存, D_i 为下游需求, d_i^{sat} 为实际满足的需求量。对于最上游企业, 采购成本项为 0。

3 算法设计

3.1 DQN 系列基线

基于课程提供的 DQN, 本研究实现了以下消融:

- **DQN**: 标准深度 Q 网络 [Mnih et al., 2015]。
- **Double DQN**: 使用在线网络选动作、目标网络估值, 缓解 Q 值高估 [Van Hasselt et al., 2016]。
- **Dueling DQN**: 将 Q 函数分解为状态值 $V(s)$ 与优势函数 $A(s, a)$ 之和 [Wang et al., 2016]。
- **Dueling Double DQN**: 同时融合 Double 目标与 Dueling 结构。

所有 DQN 变体共享超参数: 隐藏层 64-64、经验池 10000、批量 64、目标网络软更新 $\tau = 0.001$ 、 ϵ 从 1.0 衰减至 0.05。

3.2 PPO 实现与改进

3.2.1 基础 PPO

PPO 采用离散动作 Actor-Critic 架构 [Schulman et al., 2017], 目标函数为 Clipped Surrogate Objective:

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (4)$$

其中 $r_t(\theta) = \pi_\theta(a_t|s_t)/\pi_{\theta_{\text{old}}}(a_t|s_t)$, 优势函数 $\hat{A}_t$ 通过 GAE 计算 [Schulman et al., 2015]:

$$\hat{A}_t = \delta_t + (\gamma\lambda)\delta_{t+1} + \dots + (\gamma\lambda)^{T-t}\delta_T. \quad (5)$$

3.2.2 稳定化技巧

为了提升 PPO 在小样本、离散动作任务上的稳定性, 本研究实现了以下改进:

- (1) **Reward scaling**: 将原始奖励乘以 0.001, 使 PPO 的 value loss 与 policy loss 量级匹配。
- (2) **Clipped value loss**: 对 value function 的更新也使用 clipping, 避免 value 网络剧烈变化。

- (3) **Gradient clipping**: 限制梯度范数最大为 0.5。
- (4) **KL early stopping**: 每次 update epoch 后估计 $D_{\text{KL}}(\pi_{\text{old}} \parallel \pi_{\text{new}})$, 若超过 0.015 则提前终止该轮更新。
- (5) **Learning rate / entropy decay**: 训练过程中线性衰减学习率与熵正则系数。
- (6) **Best checkpoint**: 每 50 个 episode 在固定 20 个 episode 上评估当前策略, 保存并恢复最优检查点。

3.2.3 算法扩展

在基础 PPO 之上, 还尝试以下扩展:

- **Centralized critic**: Critic 观测全局状态 (3 个企业的局部观测拼接), Actor 仍使用局部观测。
- **Reward shaping**: 包括 SRDQN 风格的反馈奖励 (奖励代理其他企业的平均利润)、外部性惩罚 (库存与缺货成本)、动作平滑惩罚等 [Gijbrenchts et al., 2020]。
- **EMA evaluation model**: 维护策略网络的指数移动平均副本, 用于更稳定的评估。

3.3 SAC 基线

本研究还实现了离散动作 SAC [Haarnoja et al., 2018] 作为补充对比, 采用 twin Q 网络与自动熵调节, 但在本任务上表现不稳定 (详见实验结果)。

4 实验设置

4.1 超参数与训练流程

主要实验在 3 个随机种子 [42, 123, 456] 上重复, 每个 seed 训练后使用 20 个 episode 评估。PPO 训练 1000 个 episode, DQN 系列训练 300 个 episode。评估时背景策略固定为 random。

PPO 关键超参数如表 1 所示。

4.2 评估指标

采用 3-seed 平均奖励 (mean reward) 作为主要指标, 并报告每个 seed 的均值以及跨 seed 标准差, 以衡量算法稳定性。

5 实验结果

5.1 算法消融结果

表 2 给出了所有基线与改进算法在 3-seed 上的评估结果。

表 1: PPO 关键超参数

超参数	默认值
hidden size	256
batch size	256
learning rate	1×10^{-4}
rollout episodes	4
update epochs	20
clip ϵ	0.2
value coef	0.5
entropy coef	0.05
target KL	0.015
reward scale	0.001
max grad norm	0.5
GAE λ	0.95

表 2: 各算法 3-seed 评估结果 (每个 seed 20 episode)

方法	平均 reward	标准差	seed 均值
random	-3435.22	2511.29	-2659.18 / -4013.85 / -3632.62
base_stock	-3885.23	824.78	-3979.18 / -3787.88 / -3888.65
DQN	760.93	109.97	789.95 / 744.67 / 748.17
Double DQN	797.19	117.85	813.00 / 777.22 / 801.35
Dueling DQN	781.23	126.05	792.53 / 762.03 / 789.15
Dueling Double DQN	804.46	114.58	838.55 / 787.10 / 787.72
PPO (改进后)	779.59	123.68	753.50 / 784.72 / 800.55
SAC	-7305.86	6426.45	-11431.58 / -11120.33 / 634.33

Baseline 与算法消融评估结果 (误差线为标准差)




图 1: 各算法 3-seed 平均奖励对比 (含标准差)

5.2 结果分析

- **DQN 系列**表现最为稳定。Dueling Double DQN 以 804.46 的平均奖励位列第一，说明在网络结构与学习目标上的改进对抑制 Q 值高估有效。
- **PPO** 在改进后平均奖励达到 779.59，部分 seed 达到 800 以上，但在 seed 42 上仅 753.50，仍存在一定方差。相比最初实现 (seed 123 崩溃至 76.15)，KL early stopping、reward scaling 与 best checkpoint 显著提升了稳定性。
- **SAC** 在本任务上极不稳定，仅 seed 456 收敛至正值，其余两个 seed 因离散动作与奖励尺度不匹配导致策略崩溃。
- 规则策略 random 与 base_stock 均为负奖励，远低于学习算法，说明学习环境中的局部优化空间较大。

5.3 训练曲线

图 2 与图 3 分别展示了 Dueling Double DQN 与改进后 PPO 的训练曲线 (含 3-seed 均值与标准差带)。




图 2: Dueling Double DQN 训练曲线

5.4 策略行为对比

通过固定 seed 运行一个 episode，可对比不同策略的订货量、库存与即时奖励。Dueling Double DQN 学会了在需求波动时保持相对平稳的订货策略，而 PPO 在某些 seed 下仍存在订货量震荡，这可能是其方差较大的原因。

5.5 背景策略与多智能体扩展

表 3 比较了在其他企业采用 random 与 base_stock 背景下的 Dueling Double DQN 表现。两者均值接近，但 base_stock 背景标准差更低，说明规则化上下游可降低评估波动。




图 3: 改进后 PPO 训练曲线




图 4: 最终策略订购行为对比

表 3: 不同背景策略下的 Dueling Double DQN (seed=42)

背景策略	平均 reward	标准差
random background	831.95	104.36
base_stock background	824.00	73.38

表 4 给出了多智能体实验结果。独立训练三个 Dueling Double DQN 后，全链路 total reward 从负值提升至 3426.55，显著高于单智能体只优化企业 1 的情景（-4663.73）。

表 4: 多智能体实验结果（seed=42, 20 episode）

方法	企业 0	企业 1	企业 2	全链路 total
random_all	-3763.38	-4023.73	3957.10	-3830.00
base_stock_all	-3509.93	-3521.32	3414.05	-3617.20
single_agent_ddqn	-3057.18	831.95	-2438.50	-4663.73
multiagent_ddqn	468.77	538.60	2419.18	3426.55

6 核心代码说明

PPO 的 KL early stopping 实现如下：

```

1 if self.target_kl is not None:
2     with torch.no_grad():
3         _, new_log_probs, _ = self.net.evaluate(
4             states, actions,
5             critic_states if critic_states is not None else None)
6         kl = (old_log_probs - new_log_probs).mean().item()
7         if kl > self.target_kl:
8             break

```

Best-checkpoint 训练流程会周期性评估当前策略，保存并恢复最优模型：

```

1 if eval_mean > best_eval:
2     best_eval = eval_mean
3     agent.save(best_path)
4 # 训练结束后
5 if best_path.exists():
6     agent.load(best_path)

```

Centralized critic 通过将全局状态拼接后输入 critic_body，使 value 估计能够利用其他企业的信息，而 actor 仍基于局部观测决策。

7 讨论与未来工作

7.1 PPO 尚未稳定超过 DQN 的可能原因

- (1) **样本效率**：DQN 通过经验回放重复使用样本，300 episode 即可获得稳定策略；PPO 的 on-policy 特性导致 1000 episode 的有效样本利用率仍较低。
- (2) **离散动作与策略梯度**：动作空间小且订货量为整数，策略网络的 logits 容易过早坍缩到确定性动作，熵衰减后探索不足。
- (3) **奖励稀疏与尺度**：单步奖励波动大，虽然已进行 reward scaling，但不同 seed 下优势估计方差仍可能过大。

- (4) **背景策略随机性**: 上下游为 random 时, 环境动态高度非平稳, 策略梯度方法对分布漂移更敏感。

7.2 后续方向

- 引入离线策略技巧 (如 PPO with replay buffer / AWAC) 提升 PPO 样本效率。
- 对 PPO 实施课程学习或预训练初始化, 先用 base_stock 背景预训练, 再迁移到 random 背景。
- 将 PPO 扩展为 multi-agent (IPPO/MAPPO), 利用 centralized training with decentralized execution 进一步降低方差。
- 尝试更激进的状态增强 (需求历史、在途库存) 以帮助策略网络更好地估计未来到货。

8 结论

本研究在啤酒游戏三阶供应链环境中复现并改进了 DQN、PPO 与 SAC 算法。实验表明, Dueling Double DQN 是当前任务上最稳健的高性能基线, 平均奖励达 804.46。通过 GAE、reward scaling、KL early stopping、best checkpoint 与 centralized critic 等改进, PPO 的稳定性显著提升, 平均奖励达到 779.59, 部分 seed 超过 800, 但尚未在所有 seed 上稳定超过 DQN。未来可通过提升样本效率、课程学习与多智能体训练进一步缩小并超越该差距。

参考文献

- Joren Gijsbrechts, Robert N. Boute, Jan A. Van Mieghem, and Dennis J. Zhang. Deep reinforcement learning for multi-echelon inventory management in the beer game. *Available at SSRN*, 2020.
- Tuomas Haarnoja, Aurick Zhou, Kristian Hartikainen, George Tucker, Sehoon Ha, Jie Tan, Vikash Kumar, Henry Zhu, Abhishek Gupta, Pieter Abbeel, et al. Soft actor-critic algorithms and applications. *arXiv preprint arXiv:1812.05905*, 2018.
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. *arXiv preprint arXiv:1506.02438*, 2015.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- Hado Van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double q-learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 30, 2016.
- Ziyu Wang, Tom Schaul, Matteo Hessel, Hado Hasselt, Marc Lanctot, and Nando Freitas. Dueling network architectures for deep reinforcement learning. In *International Conference on Machine Learning*, pages 1995–2003, 2016.